

Proyecto de Análisis de Datos Personales de Instagram

Fase	Entregable
Fase 1: Exploración y comprensión de los datos	Documento con estructura de carpetas, lista de JSON principales, descripción del contenido y reflexión.
Fase 2: Limpieza y consolidación	Notebook con funciones/celdas de carga, análisis de calidad (nulos/duplicados), dataset limpio exportado a CSV e informe de transformaciones.
Fase 3: Análisis exploratorio (EDA)	Informe EDA con visualizaciones, insights/patrones y comparación por periodos + reflexión.
Fase 4: Machine Learning	Notebook de ML con al menos 2 modelos, evaluación con métricas, interpretación de resultados y conclusiones.
Fase 5: Análisis de multimedia (opcional)	Análisis de paleta de colores, clasificación de contenido visual, análisis temporal de estilo y dashboard visual (opcional).
Entrega final	Notebooks organizados por fase + informe ejecutivo (PDF, 10–15 páginas) + presentación (5–10 minutos).

Objetivos del Proyecto

Este proyecto te permitirá:

- Comprender la estructura de tus datos personales digitales
- Aplicar técnicas de limpieza y transformación de datos
- Realizar análisis exploratorio de datos (EDA)
- Implementar modelos de Machine Learning
- Crear dashboards interactivos con visualizaciones
- Reflexionar sobre tu privacidad y comportamiento digital

FASE 1: Exploración y Comprensión de los Datos

1.1 Extracción de Datos

Descargar y familiarizarse con la estructura de datos de Instagram

Pasos:

1. Descarga tu información desde Instagram:

- Ve a Configuración → Seguridad → Descargar información
- Selecciona formato JSON
- Descarga el archivo ZIP

2. Explora la estructura:

Entregable 1: Documento con

- Estructura de carpetas encontradas
- Lista de archivos JSON principales

- Descripción de qué tipo de información contiene cada archivo

Reflexión: ¿Qué te sorprende de los datos que Instagram tiene sobre ti?

FASE 2: Limpieza y Consolidación de Datos

2.1 Carga de Datos Principales

Archivos clave a procesar:

- posts_1.json: Tus publicaciones
- stories.json: Historias publicadas
- liked_posts.json: Posts que te gustaron
- followers_1.json: Seguidores
- following.json: Usuarios que sigues
- post_comments_1.json: Comentarios que hiciste

2.2 Limpieza de Datos

Tareas de limpieza:

1. **Manejo de valores nulos**
2. **Conversión de timestamps** a fechas legibles
3. **Decodificación de caracteres** UTF-8 (emojis, acentos)
4. **Normalización de texto** en títulos y comentarios
5. **Extracción de metadatos** EXIF de fotos (Opcional)

Limpia y normaliza texto con caracteres especiales. Para decodificar caracteres UTF-8 mal codificados:

```
def limpiar_texto(texto):
    """Limpia y normaliza texto con caracteres especiales"""
    if pd.isna(texto) or texto == '':
        return None
    # Decodificar caracteres UTF-8 mal codificados
    try:
        texto = texto.encode('latin1').decode('utf-8')
    except:
        pass
    return texto.strip()
```

```
comments=pd.read_json('post_comments_1.json')
comments=pd.json_normalize(comments['string_map_data'])
comments['Comment.value'] = comments['Comment.value'].apply(limpiar_texto)
comments
```

	Comment.value	Media	Owner.value	Time.timestamp
0	Guapa 🍷		[REDACTED]	1747975147
1	🍷		[REDACTED]tt	1746977607
2	Pregunta seria de [REDACTED] "no te salió un cocodri...		[REDACTED]	1710468865
3	Me derrito! Que hermosa foto. Qué guapos y fel...		[REDACTED]	1707927348
4	Felicidades!!! Un abrazote 🍷🍷		[REDACTED]	1695951968

Entregable 2: Notebook con:

- Funciones de carga para cada tipo de archivo (o solo la celda con el código)
- Análisis de calidad de datos (valores nulos, duplicados)
- Dataset consolidado limpio exportado a CSV
- Informe de transformaciones realizadas

FASE 3: Análisis Exploratorio de Datos

3.1 Análisis de Actividad Temporal

Preguntas a responder:

- ¿Cuándo publicas más? (día de la semana, hora del día)
- ¿Cómo ha evolucionado tu actividad en el tiempo?
- ¿Hay patrones estacionales?

3.2 Análisis de Red Social

Métricas a calcular:

- Ratio seguidores/siguiendo
- Usuarios más activos en tus interacciones
- Usuarios a los que más les das like
- Actividad de comentarios

3.3 Análisis de Contenido

Análisis a realizar:

- Frecuencia de publicación
- Tipo de contenido (posts vs stories)
- Análisis de títulos (longitud, palabras más usadas)

Entregable 3: Informe EDA con:

- Visualizaciones diferentes (distribución de datos, wordCloud etc)
- Insights y patrones encontrados
- Comparación de tu comportamiento en diferentes períodos

Reflexión: ¿Qué aprendiste sobre ti mismo/a?

FASE 4: Machine Learning

4.1 Modelo 1: Predicción de Engagement

Objetivo: Predecir qué tipo de contenido genera más engagement (basado en hora de publicación, día, longitud del título)

4.2 Modelo 2: Clustering de Comportamiento

Objetivo: Identificar patrones de comportamiento temporal usar K-means

4.3 Modelo 3: Análisis de Sentimiento de tus comments

Entregable 4: Notebook de ML con:

- Al menos 2 modelos diferentes implementados
- Evaluación de modelos (métricas apropiadas)
- Interpretación de resultados
- Conclusiones sobre utilidad de los modelos

FASE 5: Análisis de Multimedia (Opcional)

5.1 Análisis de Imágenes

Objetivo: Extraer información de las imágenes publicadas (una o varias)

```
[1]
✓ 0 s

from PIL import Image
import numpy as np
from collections import Counter

def analizar_colores_imagen(ruta_imagen):
    """Extrae los colores dominantes de una imagen"""
    img = Image.open(ruta_imagen)
    img = img.resize((150, 150)) # Reducir tamaño

    # Convertir a array
    img_array = np.array(img)

    # Obtener colores únicos
    pixels = img_array.reshape(-1, 3)

    # K-means para colores dominantes
    from sklearn.cluster import KMeans
    kmeans = KMeans(n_clusters=5)
    kmeans.fit(pixels)

    colores = kmeans.cluster_centers_.astype(int)

    return colores
```

Archivos

↑ ↺ 📁 🔍

..

sample_data

IMG_6021.JPG

app.py

followers_1.json

following.json

liked_posts.json

post_comments_1.json

posts_1.json

stories.json

```
[4]
✓ 0 s
colores_cuadritos=analizar_colores_imagen('IMG_6021.JPG')

[3]
import matplotlib.pyplot as plt
import numpy as np

def visualizar_colores_dominantes(colores):
    """Visualiza un array de colores RGB como una paleta de colores."""
    num_colores = len(colores)

    # Crear la figura y los ejes
    fig, ax = plt.subplots(1, num_colores, figsize=(num_colores * 1.5, 2))

    # Iterar sobre cada color y dibujar un cuadrado
    for i, color_rgb in enumerate(colores):
        # Normalizar los valores RGB de 0-255 a 0-1 para matplotlib
        color_norm = color_rgb / 255.0

        # Crear un cuadrado y asignarle el color
        ax[i].imshow([[color_norm]])
        ax[i].set_xticks([])
        ax[i].set_yticks([])
        ax[i].set_aspect('equal') # Asegurar que los cuadrados sean uniformes

    fig.suptitle('Paleta de Colores Dominantes', fontsize=16)
    plt.tight_layout(rect=[0, 0.03, 1, 0.95]) # Ajustar el diseño para el título
    plt.show()
```



5.2 Clasificación de Contenido Visual

Archivos

- imagenes
 - 01-01-04_...
 - 02-06-05_...
 - 04-11-04_1...
 - 19-10-04_...
 - 21-11-04_1...
 - 27-04-05_...
 - 27-04-05_...
 - Bichovikb...
 - DSC00634...
 - DSC00638...
 - DSC00644...
 - DSC00645...
 - DSC00646...
 - DSC01103...

Disco73.74 GB de espacio disq

```
[1]  
✓ 0 s  
ruta_carpeta_imagenes='imagenes'
```

```
[5]  
import os  
from collections import Counter  
from transformers import pipeline  
  
classifier = pipeline("image-classification",  
                      model="google/vit-base-patch16-224") #si no detecta las categorías bien, hay que probar otros modelos o especificar que este no categoriza bien  
  
categorias = []  
  
for imagen in os.listdir(ruta_carpeta_imagenes):  
    ruta = os.path.join(ruta_carpeta_imagenes, imagen)  
    try:  
        resultado = classifier(ruta)  
        categorias.append(resultado[0]['label'])  
    except:  
        continue  
  
# Contar categorias  
conteo = Counter(categorias)
```

```
[6]  
✓ 0 s  
conteo  
Counter(['studio couch, day bed': 1,  
        'lynx, catamount': 4,  
        'Egyptian cat': 2,  
        'swing': 1,  
        'sunglass': 1,  
        'library': 2,  
        'ice lolly, lolly, lollipop, popsicle': 1,  
        'cellular telephone, cellular phone, cellphone, cell, mobile phone': 1,  
        'drumstick': 1,
```

Entregable 5 (Opcional):

- Análisis de paleta de colores dominante
- Clasificación automática de tipo de contenido (selfies, comida, paisajes, etc.)
- Análisis temporal de cambios en estilo visual
- Dashboard visual con ejemplos de imágenes

ENTREGA FINAL

1. Componentes del Proyecto Final

- Notebooks organizados por fase de limpieza y análisis

2. Informe Ejecutivo (PDF, 10-15 páginas):

- Resumen ejecutivo
- Metodología
- Principales hallazgos
- Visualizaciones clave
- Resultados de ML
- Reflexiones sobre privacidad digital
- Conclusiones y aprendizajes

3. Presentación (5-10 minutos):

- Demo en vivo del dashboard explicativo
- 3 insights más interesantes
- Lección aprendida sobre tus datos
- Recomendaciones para otros

Criterios de Evaluación

Limpieza de Datos 15% Calidad del proceso de limpieza y transformación

EDA 20% Profundidad del análisis exploratorio y visualizaciones

Machine Learning 25% Implementación correcta, evaluación e interpretación

Código 10% Organización, documentación y buenas prácticas

Informe/Presentación 10% Claridad, insights y reflexiones

Privacidad y Ética

- Usa datos anonimizados para ejemplos
- Reflexiona sobre qué empresas saben de ti
- Considera qué información es sensible

Preguntas Frecuentes

P: ¿Qué hago si no tengo suficientes datos?

R: Puedes complementar con datos agregados de otros compañeros (anonimizados)

P: ¿Puedo usar otros modelos de ML?

R: Los sugeridos son ejemplos. Explora modelos que te interesen.

P: ¿Qué hago con los datos multimedia si son muy pesados?

R: Trabaja con una muestra representativa o usa técnicas de compresión.

P: ¿Cómo anonimizo datos para presentar?

R: Reemplaza nombres reales con pseudónimos, difumina fotos con caras, y usa rangos en lugar de valores exactos.

El objetivo no es solo el análisis técnico, sino también reflexionar sobre tu huella digital.

SPOTIFY

Fase	Entregable
Fase 1: Exploración y comprensión de los datos	Documento con estructura de carpetas, lista de JSON principales, descripción del contenido y reflexión.
Fase 2: Limpieza y consolidación	Notebook con funciones/celdas de carga, análisis de calidad (nulos/duplicados), dataset limpio exportado a CSV e informe de transformaciones.
Fase 3: Análisis exploratorio (EDA)	Informe EDA con visualizaciones, insights/patrones y comparación por periodos + reflexión.
Fase 4: Machine Learning	Notebook de ML con al menos 2 modelos, evaluación con métricas, interpretación de resultados y conclusiones.
Fase 5: Análisis de multimedia (opcional)	Análisis de paleta de colores, clasificación de contenido visual, análisis temporal de estilo y dashboard visual (opcional).
Entrega final	Notebooks organizados por fase + informe ejecutivo (PDF, 10–15 páginas) + presentación (5–10 minutos).

Spotify

Análisis 1: Patrones Temporales

- Distribución de escucha por hora del día
- Actividad por día de la semana
- Tendencia mensual de consumo
- Mapa de calor día × hora
- Identifica tus horas y días pico
- Total de artistas únicos escuchados
- Total de canciones únicas escuchadas
- Artista más escuchado: Nombre (# reproducciones)
- Canción más escuchada: Nombre (# reproducciones)

Análisis 2: Top Contenido

- Top 20 artistas y canciones más reproducidas
- Diversidad musical por mes (o año)
- Tasa de completación vs skip
- Análisis de concentración musical (GÉNEROS O ARTISTAS)
- Visualizaciones de barras horizontales

Análisis 3: Comportamiento y Sesiones

- Análisis de duración de sesiones
- Comportamiento de skip (completas/parciales/saltadas)

- Tendencia de descubrimiento musical
- Patrones de inicio de sesiones

ENTREGA FINAL

1. Componentes del Proyecto Final

- Notebooks organizados por fase de limpieza y análisis

2. Informe Ejecutivo (PDF, 10-15 páginas):

- Resumen ejecutivo
- Metodología
- Principales hallazgos
- Visualizaciones clave
- Resultados de ML
- Reflexiones sobre privacidad digital
- Conclusiones y aprendizajes

3. Presentación (5-10 minutos):

- Demo en vivo del dashboard explicativo
- 3 insights más interesantes
- Lección aprendida sobre tus datos
- Recomendaciones para otros

Criterios de Evaluación

Limpieza de Datos 15% Calidad del proceso de limpieza y transformación

EDA 20% Profundidad del análisis exploratorio y visualizaciones

Machine Learning 25% Implementación correcta, evaluación e interpretación

Código 10% Organización, documentación y buenas prácticas

Informe/Presentación 10% Claridad, insights y reflexiones